

RELATÓRIO — EXIGIDO PELO ENUNCIADO

Disciplina: Fundamentos de Machine Learning

Ferramenta: Orange Data Mining

Aluno: Fábio Ferreira de Andrade

Base de dados: telecom_churn_complete.xlsx

Este trabalho tem como objetivo desenvolver um modelo preditivo de Machine Learning capaz de identificar clientes com alto risco de cancelamento de serviço (churn) em uma operadora de telecomunicações.

A solução foi construída utilizando a ferramenta Orange Data Mining, seguindo rigorosamente o roteiro metodológico proposto no enunciado, contemplando as etapas de preparação dos dados, seleção de modelos, validação, interpretabilidade e simulação de previsão para um novo cliente. O problema de churn é crítico em telecomunicações, pois a retenção de clientes é financeiramente mais eficiente do que a aquisição de novos, tornando modelos preditivos uma ferramenta estratégica para tomada de decisão.

1.d) Análise prévia das variáveis preditoras (antes da modelagem)

Antes de iniciar a etapa de modelagem, foi realizada uma análise conceitual dos nomes das variáveis disponíveis na base de dados, com o objetivo de estimar sua relevância potencial para a previsão de churn. Cada variável preditora recebeu uma nota de 0 a 100, onde 0 representa irrelevância total e 100 representa alta importância esperada para explicar o cancelamento do cliente.

Tabela 1 – Importância esperada das variáveis (análise prévia)

<i>Variável</i>	<i>Nota (0–100)</i>	<i>Justificativa</i>
account_age_weeks	40	O tempo de relacionamento pode indicar fidelização, mas isoladamente nem sempre diferencia clientes que cancelam.
contract_renewal	95	A renovação de contrato indica forte intenção de permanência do cliente.
data_plan	60	Ter plano de dados pode aumentar dependência do serviço, mas não garante retenção.
data_usage_gb	35	Maior uso pode sugerir valor percebido, porém neste contexto tende a ter baixo poder preditivo isolado.
customer_service_calls	90	Muitas ligações ao suporte geralmente indicam insatisfação recorrente.
day_minutes	80	Uso intenso do serviço principal pode estar associado a maior retenção.
day_calls	50	A quantidade de chamadas, por si só, tende a ser pouco informativa.
monthly_charge	95	O valor da mensalidade é um dos principais fatores de decisão do cliente sobre permanecer ou cancelar o serviço.
overage_fee	65	Taxas extras inesperadas tendem a gerar insatisfação.
roam_minutes	60	Uso de roaming pode indicar perfil específico associado a custo e possível insatisfação.

3.d) Seleção do melhor modelo com base nas métricas

Após a avaliação de múltiplos algoritmos utilizando validação cruzada estratificada (k-fold, k=10), foram testados 16 modelos distribuídos entre quatro famílias de algoritmos: Logistic Regression, Random Forest, Gradient Boosting e Neural Networks. Cada algoritmo foi avaliado com pelo menos quatro configurações distintas de hiperparâmetros, conforme exigido no enunciado.

Tabela 2 – Top 5 modelos avaliados (validação cruzada k=10)

<i>Modelo</i>	<i>AUC</i>	<i>Accuracy</i>	<i>F1</i>	<i>MCC</i>
RF (100 trees, 3 feats) 🏆	0.904	94.0%	0.937	0.743
GBM (100 trees)	0.905	93.6%	0.933	0.723
RF (100 trees, 3 feats)	0.904	93.7%	0.934	0.729
RF (300 trees, 4 feats)	0.899	93.7%	0.934	0.729
GBM (50 trees)	0.900	93.7%	0.933	0.724

O modelo que apresentou o melhor desempenho geral foi o Random Forest com 100 árvores e 3 variáveis por divisão. A escolha se justifica pela combinação ótima de métricas. Embora o GBM (100 trees) apresente AUC ligeiramente superior (0.905 vs 0.904), uma diferença de apenas 0.001 é estatisticamente insignificante. O Random Forest selecionado supera o GBM em todas as demais métricas: Accuracy (94.0% vs 93.6%), F1-Score (0.937 vs 0.933) e, especialmente, MCC (0.743 vs 0.723). O MCC (Matthews Correlation Coefficient) é particularmente relevante para problemas de classificação binária, pois considera verdadeiros e falsos positivos e negativos de forma balanceada.

Além das vantagens métricas, o Random Forest oferece maior interpretabilidade que Gradient Boosting, facilitando a extração de insights de negócio através da análise de importância das variáveis. O modelo com 3 features por divisão também demonstra maior eficiência computacional e menor complexidade em comparação com configurações que utilizam 4 features, reduzindo o risco de overfitting sem comprometer o desempenho.

4.c) Desempenho do modelo nos dados de teste (validação final)

O modelo Random Forest selecionado foi treinado utilizando 100% do conjunto de treino (80% dos dados totais) e posteriormente avaliado no conjunto de teste (20% hold-out), que permaneceu intocado até esta etapa final. As métricas obtidas no conjunto de teste demonstraram desempenho consistente em relação à validação cruzada.

Tabela 3 – Comparação: Validação Cruzada vs Teste Final

<i>Métrica</i>	<i>Cross-Val</i>	<i>Teste</i>	<i>Variação</i>
AUC	0.904	0.892	-1.3%
Accuracy	94.0%	92.3%	-1.5%
F1-Score	0.937	0.921	-1.7%
Precision	-----	92.3%	-----
Recall	-----	92.6%	-----
MCC	0.743	0.676	-9.0%

O modelo manteve performance superior a 92% em todas as métricas principais no conjunto de teste, com queda inferior a 2% no AUC, Accuracy e F1-Score. A maior variação foi observada no MCC (9.0%), porém o valor final de 0.676 ainda representa correlação forte e desempenho robusto. Esse comportamento indica que o modelo não apresentou sinais relevantes de overfitting, mantendo capacidade adequada de generalização para dados não vistos. A degradação observada é esperada e aceitável, característica de modelos bem ajustados que não memorizaram os dados de treino.

5.b) Comparação entre importância esperada e importância real das variáveis

A importância real das variáveis foi extraída utilizando Permutation Feature Importance, com base na métrica AUC, aplicada ao modelo Random Forest final. Esta técnica mede o impacto de cada variável no desempenho do modelo através da permutação aleatória dos valores de cada feature.

Tabela 4 – Comparação: Importância Esperada vs Importância Real

<i>Variável</i>	<i>Nota Esperada</i>	<i>Ranking Real</i>	<i>Alinhamento</i>
customer_service_calls	90	1º	Alinhado
contract_renewal	95	2º	Alinhado
monthly_charge	95	3º	Alinhado
day_minutes	80	4º	Alinhado
roam_minutes	60	5º	Alinhado
overage_fee	65	6º	Alinhado
data_plan	60	7º	Alinhado
account_age_weeks	40	8º	Alinhado
day_calls	50	9º	Alinhado
data_usage_gb	35	10º	Alinhado

Comparação dos resultados

O resultado foi amplamente consistente com as expectativas iniciais, demonstrando alinhamento em 100% das variáveis. As três variáveis consideradas mais relevantes na análise prévia (**customer_service_calls**, **contract_renewal** e **monthly_charge**) confirmaram-se como as mais importantes segundo o modelo, validando a análise conceitual inicial. Destaca-se que **customer_service_calls** emergiu como a variável mais importante, superando inclusive **monthly_charge**. Este resultado reforça a hipótese de que a insatisfação recorrente do cliente, manifestada através de múltiplos contatos com o suporte, é o preditor mais forte de cancelamento, mesmo acima do valor financeiro da mensalidade.

Variáveis inicialmente consideradas de importância moderada ou baixa, como **account_age_weeks** e **data_usage_gb**, confirmaram posições inferiores no ranking, validando a hipótese de que o tempo de relacionamento e o volume de uso de dados, isoladamente, têm poder preditivo limitado para este problema.

Não foram observadas variáveis julgadas irrelevantes que o modelo tenha considerado cruciais, nem o contrário, indicando que a análise conceitual prévia capturou adequadamente a estrutura do problema de negócio. Essas diferenças entre expectativa e resultado podem ser explicadas pelo fato de que modelos baseados em dados capturam interações e padrões não triviais, que nem sempre são evidentes apenas pela análise conceitual das variáveis.

6.c) Previsão para o novo cliente (simulação)

O modelo treinado foi aplicado a um novo cliente com o perfil especificado no enunciado, utilizando as seguintes características:

account_age_weeks	128
contract_renewal	1
data_plan	0
data_usage_gb	0.0
customer_service_calls	4
day_minutes	265.1
day_calls	110
monthly_charge	45.0
overage_fee	10.5
roam_minutes	14.2

Resultado da previsão

Classe prevista: NÃO CHURN (cliente deve permanecer)

Probabilidade de permanência: 53%

Probabilidade de cancelamento: 47%

Interpretação

O cliente apresenta um perfil limítrofe, com probabilidades quase equilibradas (53% vs 47%). Embora o modelo preveja permanência, a diferença de apenas 6 pontos percentuais indica que este cliente está na fronteira de decisão do modelo e representa risco moderado-alto.

Fatores que contribuem para o risco: O cliente realizou 4 ligações ao suporte (customer_service_calls), variável identificada como a mais importante para predição de churn. Este comportamento sinaliza possível insatisfação recorrente. Adicionalmente, a cobrança de taxa extra (overage_fee: 10.5) pode ter gerado desconforto adicional.

Fatores que favorecem a retenção: O cliente renovou o contrato (contract_renewal: 1), sinalizando intenção de permanência no relacionamento. A mensalidade relativamente acessível (monthly_charge: 45.0) e o histórico de relacionamento de 128 semanas (~2.5 anos) também contribuem positivamente.

Ações recomendadas

Dada a classificação limítrofe, recomenda-se atenção especial da área de retenção. Caso o risco aumente ou sinais adicionais de insatisfação sejam detectados, a empresa poderia adotar as seguintes ações:

- Contato proativo do time de retenção para entender as causas das 4 ligações ao suporte e resolver pendências.
- Ofertas personalizadas ou revisão de plano, especialmente considerando a eliminação ou redução da taxa extra (overage_fee).
- Monitoramento próximo nos próximos meses para detectar sinais de deterioração no relacionamento.
- Reforço do valor percebido através de comunicação sobre benefícios do contrato renovado.

Considerações Finais

Este projeto exigiu uma abordagem cuidadosa e estruturada, envolvendo múltiplos algoritmos (16 modelos testados), validação cruzada estratificada, análise de interpretabilidade e simulação de cenário real de negócio. Apesar da complexidade técnica, o trabalho proporcionou aprendizado significativo em Machine Learning aplicado através de ferramenta no-code, além de práticas alinhadas ao que é utilizado em ambientes profissionais de ciência de dados.

O modelo final Random Forest (100 árvores, 3 features) demonstrou excelente capacidade preditiva (AUC 0.892 no teste), boa generalização (sem overfitting grave) e interpretabilidade adequada para aplicação em contexto de negócio. A análise de importância das variáveis gerou insights acionáveis, especialmente ao confirmar que a insatisfação recorrente (medida por customer_service_calls) é o principal driver de cancelamento, superando inclusive o custo financeiro do serviço.

Declaração de Uso de IA

Este trabalho foi desenvolvido com apoio de ferramentas de Inteligência Artificial generativa, utilizadas exclusivamente como assistente para:

Organização de ideias
Revisão técnica
Apoio conceitual

Responsabilidade

Todo o conteúdo final, análises, insights, decisões técnicas e conclusões foram integralmente revisados, validados e aprovados pelo autor. A inteligência artificial foi utilizada como ferramenta de apoio ao desenvolvimento, complementando o trabalho intelectual do autor, não o substituindo. O uso de IA seguiu princípios éticos e educacionais, conforme orientações oficiais.

Referências sobre Disclosure de IA

- [Princeton University - Disclosing the Use of AI](#)
- [Arizona State University - Acknowledging AI Usage](#)
- [AID Framework - AI Disclosure](#)